

Data Understanding

13524008 Agatha Tatianingseto

13524089 Aurelia Jennifer Gunawan

Kerjakan soal berikut secara berkelompok 2 orang, open book, tanpa menggunakan bantuan tool pemrograman/AI.

Sebuah bank ingin membangun model AI untuk memprediksi **kredit macet (Credit Default Prediction)** pada nasabah. Berikut adalah data yang diperoleh dari beberapa cabang bank:

ID Nasabah	Umur	Pendapatan (Juta/bln)	StatusNikah	LamaKerja (th)	Jumlah Pinjaman (Juta)	Kredit Macet
N001	35	12	Menikah	10	100	Tidak
N002	42	18	Menikah	15	150	Tidak
N003	29	8	Belum Menikah	4	80	Ya
N004	38	14	Menikah	12	120	Tidak
N005	45	20	Menikah	18	200	Tidak
N006	31	9	Belum Menikah	5	90	Ya
N007	500	15	Menikah	20	130	Tidak
N008	27	-	Belum Menikah	2	75	Ya
N009	34	11	menikah	8	110	Tidak
N010	40	16	Menikah	14	140	Tidak
N011	25	7	Single	1	60	Ya
N012	36	13	Menikah	11	115	Tidak
N013	44	19	Menikah	-2	170	Tidak
N014	33	10	Belum Menikah	6	95	Ya
N015	39	15	Menikah	13	125	Tidak

N016	28	9	Belum Menikah	3	85	Ya
N017	41	17	MENIKAH	16	155	Tidak

N018	30	8	Belum Menikah	5	9000	Ya
N019	37	14	Menikah	9	130	Tidak
N019	37	14	Menikah	9	130	Tidak

Lakukan pemeriksaan kualitas data tersebut sesuai langkah berikut.

A. Pemeriksaan Kelengkapan Data

1. Berapa jumlah record dan jumlah atribut pada dataset?

Terdapat 20 record dengan 6 atribut independen dan 1 atribut dependen

2. Apakah terdapat data yang hilang (*missing value*)? Sebutkan lokasi dan atributnya.

Terdapat missing value pada kolom pendapatan pada row 8

3. Hitung persentase missing value pada setiap atribut.

$$\text{persentase missing value} = \frac{1 \text{ record}}{20 \text{ record}} \times 100\% = 5\%$$

B. Pemeriksaan Kualitas Data

4. Identifikasi seluruh masalah kualitas data yang terdapat pada dataset.

1. Terdapat salah input data pada atribut lama kerja pada row 13, dimana LamaKerja (th) memiliki value -2
2. Terdapat salah input pada atribut Umur, pada id N007 memiliki value 500
3. Terdapat missing value pada atribut pendapatan pada row 8
4. Terdapat inkonsistensi kelompok pada StatusNikah pada row 9. Dimana normal nya digunakan dengan awalan huruf besar yaitu 'Menikah', tetapi pada row 9 itu digunakan awalan huruf kecil yaitu 'menikah'
5. Terdapat inkonsistensi kelompok pada StatusNikah pada row 17, Dimana normalnya hanya huruf pertama yang kapital. Tetapi pada row tersebut menjadi 'MENIKAH'.
6. Terdapat inkonsistensi pada kelompok value, pada StatusNikah dengan ID N011, dimana seharusnya value hanya berupa binary yaitu Menikah/Belum Menikah. Tetapi pada instance yang disebutkan, memiliki value 'Single'
7. Terdapat data duplikat yaitu pada row 19 dan 20
8. Terdapat outlier data pinjaman 9000 juta pada row 18

5. Kelompokkan setiap masalah ke dalam kategori berikut:

- a. Missing Value
- b. Data Tidak Konsisten
- c. Data Duplikat
- d. Outlier / Data Error

- Masalah 1 (Terdapat salah input data pada atribut lama kerja pada row 13) tergolong kategori masalah outlier/data error
- Masalah 2 (Terdapat salah input pada atribut Umur, pada id N007 memiliki value 500) tergolong kategori masalah outlier/data error
- Masalah 3 (Terdapat missing value pada atribut pendapatan pada row 8) tergolong kategori masalah Missing Value
- Masalah 4 (Terdapat inkonsistensi kelompok pada StatusNikah pada row 9. Dimana normal nya digunakan dengan awalan huruf besar yaitu 'Menikah', tetapi pada row 9 itu digunakan awalan huruf kecil yaitu 'menikah') tergolong kategori masalah outlier/data error
- Masalah 5 (Terdapat inkonsistensi kelompok pada StatusNikah pada row 17, Dimana normalnya hanya huruf pertama yang kapital. Tetapi pada row tersebut menjadi 'MENIKAH') tergolong kategori masalah outlier/data error
- Masalah 6 (Terdapat inkonsistensi pada kelompok value, pada StatusNikah dengan ID N011, dimana seharusnya value hanya berupa binary yaitu Menikah/Belum Menikah. Tetapi pada instance yang disebutkan, memiliki value 'Single') tergolong kategori masalah outlier/data error
- Masalah 7 (Terdapat data duplikat yaitu pada row 19 dan 20) tergolong kategori masalah Data Duplikat
- Masalah 8 (Terdapat outlier data pinjaman 9000 juta pada row 18) tergolong kategori masalah outlier/data error

C. Analisis Dampak

6. Jelaskan dampak masing-masing masalah kualitas data terhadap model klasifikasi yang akan dibangun.

Data error

- Membuat representasi data lain yang sebenarnya memiliki makna yang sama. Misalnya pada atribut StatusNikah, seharusnya hanya terdapat 2 representasi data (binary) yaitu Menikah atau Belum Menikah. Tetapi dengan kondisi raw data sekarang, hal tersebut menjadikan 5 representasi data yaitu Menikah, menikah, MENIKAH, Belum Menikah,

dan single.

- Dimana sebenarnya Menikah, menikah, MENIKAH memilih makna yang sama. Serta juga pada Belum Menikah dan single.
- Apabila model menggunakan poin sebagai evaluasi, dengan representasi berbeda ini dapat membuat bobot setiap komponen berbeda padahal bermakna sama

Data Duplikat

- Model menjadi bias pada representasi data tersebut
- Apabila ada splitting data, ada kemungkinan data leakage karena bisa jadi ada data test atau validation yang merupakan data training

Missing Value

- Menyebabkan ketidakakuratan model karena kehilangan representasi dari data hilang tersebut
- Karena model adalah berbasis probability, sehingga kehilangan data atau NaN menyebabkan ketidakakuratan probability tersebut.

7. Menurut Anda, masalah mana yang paling berbahaya bagi model dan mengapa?

Menurut kami, masalah yang paling berbahaya bagi model adalah masalah outlier/data error, misalnya pada atribut StatusNikah, terhadap 5 variasi nilai: Menikah, Belum Menikah, Single, menikah, MENIKAH. Model dapat menganggap kelima string tersebut 5 representasi fitur yang berbeda, padahal sebenarnya hanya ada 2 representasi fitur: Menikah dan Belum Menikah.

D. Rekomendasi Perbaikan

8. Untuk setiap masalah yang ditemukan, berikan usulan tindakan perbaikan.

- Untuk **masalah 1**, lakukan validasi nilai terhadap sumber data aktual. Jika tidak dapat dikoreksi, maka ubah menjadi *missing value* dan lakukan imputasi (dapat menggunakan metode KNN).
- Untuk **masalah 2**, lakukan koreksi nilai terhadap sumber data aktual, karena tidak mungkin umur seseorang mencapai 500 tahun. Jika tidak dapat dikoreksi, ubah menjadi *missing value* dan lakukan imputasi.
- Untuk **masalah 3**, lakukan imputasi dengan metode KNN (K-Nearest Neighbors), jadi nilai yang hilang diisi dengan nilai hasil prediksi berdasarkan kedekatan dengan data lain.
- Untuk **masalah 4**, lakukan case normalization atau standarisasi menjadi 'Menikah'.
- Untuk **masalah 5**, lakukan case normalization atau standarisasi menjadi 'Menikah'.
- Untuk **masalah 6**, lakukan pemetaan kategori Single ke Belum

Menikah.

- Untuk **masalah 7**, hapus salah satu row data yang duplikat.
- Untuk **masalah 8**, lakukan validasi dengan sumber data aktual. Jika salah input maka lakukan koreksi.

9. Tuliskan dataset final yang siap digunakan setelah dilakukan pembersihan data.

ID Nasabah	Umur	Pendapatan (Juta/bln)	StatusNikah	LamaKerja (th)	Jumlah Pinjaman (Juta)	Kredit Macet
N001	35	12	Menikah	10	100	Tidak
N002	42	18	Menikah	15	150	Tidak
N003	29	8	Belum Menikah	4	80	Ya
N004	38	14	Menikah	12	120	Tidak
N005	45	20	Menikah	18	200	Tidak
N006	31	9	Belum Menikah	5	90	Ya
N007	41	15	Menikah	20	130	Tidak
N008	27	8	Belum Menikah	2	75	Ya
N009	34	11	Menikah	8	110	Tidak
N010	40	16	Menikah	14	140	Tidak
N011	25	7	Belum Menikah	1	60	Ya
N012	36	13	Menikah	11	115	Tidak
N013	44	19	Menikah	18	170	Tidak
N014	33	10	Belum Menikah	6	95	Ya
N015	39	15	Menikah	13	125	Tidak
N016	28	9	Belum Menikah	3	85	Ya
N017	41	17	Menikah	16	155	Tidak
N018	30	8	Belum	5	9000	Ya

			Menikah			
N019	37	14	Menikah	9	130	Tidak

E. Laporan Kualitas Data

10. Buat ringkasan laporan kualitas data dalam format berikut:

Jenis Masalah	Jumlah Kasus	Lokasi Data	Rekomendasi
Missing Value	1	row 8	Lakukan imputasi dengan KNN (K-Nearest Neighbors).
Inkonsistensi	0	-	-
Duplikasi	1	row 19 & row 20	hapus salah satu duplicated row
Outlier	6	row 7, 9, 11, 13, 17, 18	Lakukan koreksi terlebih dahulu. Namun jika tidak memungkinkan untuk melakukan koreksi data, maka ubah nilai menjadi missing values dan lakukan imputasi dengan metode yang sesuai.