



IF3170 Inteligensi Artifisial

Institut Teknologi Bandung

CRISP-DM & Data Understanding

Semester I TA 2026/2027






Outline

- Review:
 - Problem Solving Agent
 - Knowledge Based Agent
 - Learning Agent
- Introduction to Data Science
- CRISP-DM
- Data Understanding






Intro to Data Science



Definisi Data Science

- Data science adalah bidang studi yang berfokus pada pemahaman, analisis, dan pengambilan keputusan berdasarkan data.
- Data science menggabungkan berbagai disiplin ilmu, termasuk statistika, matematika, komputer, dan pengetahuan domain, untuk menggali wawasan berharga dari data dan memecahkan masalah yang kompleks





Tujuan Task

01

Descriptive:

Menjelaskan keadaan bisnis saat ini melalui data historis.

02

Diagnostic:

Menjelaskan mengapa suatu masalah terjadi dengan melihat data historis.

03

Predictive:

Memproyeksikan atau memprediksi hasil masa depan berdasarkan data historis.


04

Prescriptive:

Menggunakan hasil analitik prediktif dan pengetahuan lain dengan menyarankan upaya terbaik di masa depan.



Tujuan Task





Perlu Metodologi Pengembangan

Pengembangan Sistem AI berdasar data

$\neq$

Data + Machine Learning (ML) Algorithms

Metodologi Pengembangan:

Metoda *iterative* yang dipakai untuk menyelesaikan masalah dengan menggunakan *data science* melalui urutan langkah yang ditentukan



Jenis Metodologi *Data Science*

1. Metodologi kegiatan Teknis

Kegiatan *Data Science* dianggap sebagai kegiatan teknis di bidang Teknologi Informasi ataupun Pengolahan data


2. Metodologi kegiatan bisnis

Kegiatan *Data Science* dianggap sebagai kegiatan bisnis yang terkait dengan penyelesaian suatu masalah organisasi menggunakan pendekatan data

Metodologi Teknis


Kegiatan DS/AI sebagai Kegiatan Teknikal

Knowledge Discovery and Data Mining (KDD)



<https://www.kdnuggets.com/gpspubs/aimag-kdd-overview-1996-Fayyad.pdf>

SEMMA dari SAS Institute




<https://documentation.sas.com/?docsetId=emref&docsetTarget=n061bzurmej4j3n1jnj8bbjim1a2.htm&docsetVersion=14.3&locale=en>

CRISP-DM




<https://documentation.sas.com/?docsetd=emref&docsetTarget=n061bzurmej43n1jn18bbjm1a2.htm&docsetVersion=14.3&locale=en>

IBM Data Science Methodology



<https://www.slideshare.net/JohnBRollinsPhD/foundational-methodology-for-data-science>

Microsoft's Team Data Science Process



<https://docs.microsoft.com/en-us/azure/machine-learning/team-data-science-process/overview>

Bagaimana di Indonesia?



MENTERI KETENAGAKERJAAN
REPUBLIK INDONESIA

KEPUTUSAN MENTERI KETENAGAKERJAAN
REPUBLIK INDONESIA
NOMOR 299 TAHUN 2020
TENTANG

PENETAPAN STANDAR KOMPETENSI KERJA NASIONAL INDONESIA
KATEGORI INFORMASI DAN KOMUNIKASI GOLONGAN POKOK AKTIVITAS
PEMROGRAMAN, KONSULTASI KOMPUTER DAN KEGIATAN YANG
BERHUBUNGAN DENGAN ITU (YBDI) BIDANG KEAHLIAN ARTIFICIAL
INTELLIGENCE SUBBIDANG DATA SCIENCE

TUJUAN UTAMA	FUNGSI KUNCI	FUNGSI UTAMA	FUNGSI DASAR
Menemukan pengetahuan, <i>insight</i> atau pola yang bermanfaat dari data untuk berbagai keperluan (orang mengambil keputusan atau sistem memproses lebih lanjut)	Menganalisis Kebutuhan (Requirements) Organisasi	<i>Business Understanding</i>	1. Menentukan objektif bisnis 2. Menentukan tujuan teknis 3. Membuat rencana proyek
		<i>Data Understanding</i>	4. Mengumpulkan data 5. Menelaah data 6. Memvalidasi data
	Mengembangkan model	<i>Data Preparation</i>	7. Memilah data 8. Membersihkan data 9. Mengkonstruksi data 10. Menentukan Label Data 11. Mengintegrasikan data
		<i>Modeling</i>	12. Membangun skenario pengujian 13. Membangun model
		<i>Model Evaluation</i>	14. Mengevaluasi hasil pemodelan 15. Melakukan review proses pemodelan
	Menggunakan model yang dihasilkan	<i>Deployment</i>	16. Membuat rencana deployment model 17. Melakukan deployment model 18. Melakukan rencana pemeliharaan 19. Melakukan pemeliharaan
		<i>Evaluation</i>	20. Melakukan review proyek 21. Membuat laporan akhir proyek

Standard Kompetensi Kerja Nasional (SKKNI):
KepMen Ketenagakerjaan No 299 thn 2020

Siapa yang terlibat dalam Kegiatan Data Science

Data Scientist

Mengembangkan model terbaik dari data untuk menjawab permasalahan bisnis

Data Engineer

Menyiapkan (big) data untuk diolah/dimodelkan

Data Analyst

Menganalisis/ mencari insight dari data (dan menampilkannya dalam dashboard)

Project/ Product Manager

Mengelola proyek/ produk berbasis data.

Domain Expert


Memberi arahan tentang domain permasalahan

IT People


Menyiapkan infrastruktur IT (terutama deployment)



Langkah Pengembangan Aplikasi dengan Data Science (CRISP-DM)



CRISP-DM – Phase 1: Business Understanding



1. Business Understanding: Menentukan Masalah Bisnis

Kasus: Kegagalan Kredit



westonlegal.com

Problem

Bagaimana menurunkan NPL suatu bank?

Pertanyaan

Bagaimana memperbaiki perhitungan Credit score

Measurable outcomes

% Penurunan kredit gagal bayar



Business Understanding: Determine Business Objectives

Tujuan

memahami secara menyeluruh, dari perspektif bisnis, apa yang benar-benar ingin dicapai oleh klien.

mengungkap faktor-faktor penting, yang dapat mempengaruhi hasil proyek.

Output

Background

Mencari informasi mengenai situasi bisnis dari klien di awal proyek.

Business Objectives

Deskripsikan tujuan utama dari klien dari perspektif bisnis. Selain itu biasanya terdapat tujuan/goal lain yang ingin dicapai oleh klien.

Business Success Criteria

Mendeskripsikan kriteria keberhasilan dari proyek yang dilihat dari perspektif bisnis

Business Understanding: Assess Situation

- Bagian ini mendetailkan secara lebih rinci mengenai sumber daya, kendala, asumsi dan faktor lain yang harus dipertimbangkan dalam menentukan goal dari proyek *data science*.

Output:

<i>Inventory of Resources</i>	Membuat list dari semua sumber daya yang tersedia, termasuk di dalamnya expert, data, software dan computing resource
<i>Requirements, assumptions and constraints</i>	Membuat list dari semua kebutuhan, asumsi dan kendala yang mungkin dalam sebuah proyek data science.
<i>Risks and contingencies</i>	Membuat list dari semua resiko yang mungkin terjadi dalam pelaksanaan proyek, yang bisa membuat proyek tertunda atau bahkan gagal
<i>Terminology</i>	Mengumpulkan semua terminologi yang relevan dalam proyek: bisa berupa terminologi bisnis atau terminologi data science/mining
<i>Costs and benefits</i>	Membuat analisis cost-benefit dari proyek



Business Understanding: Determine Data Science Goals


- Business goal menyatakan tujuan dalam terminologi bisnis. Sedangkan data science goal menyatakan tujuan proyek dalam istilah teknis. Misalnya, tujuan bisnis bisa berupa "Meningkatkan penjualan katalog ke pelanggan yang sudah ada". Sedangkan data science goal bisa berupa: "Memprediksi berapa banyak widget yang akan dibeli oleh pelanggan, dengan melihat histori pembelian mereka selama tiga tahun terakhir, informasi demografis (umur, gaji, kota, dll.) dan harga barang tersebut."

Output:*Data Science Goals*

Mendeskripsikan output yang ingin dicapai dari proyek, yang mendukung pencapaian tujuan bisnis (business objectives), termasuk pendekatan yang diambil (klasifikasi, regresi, clustering, prediksi, dll)

Data Science Success Criteria

Mendefinisikan kriteria keberhasilan dari proyek dalam istilah teknis. Sebagai contoh: penggunaan metric evaluasi yang sering digunakan dalam klasifikasi/regresi




Regresi/Estimasi:

Memprediksi nilai kontinyu dari kasus

- Prediksi harga rumah berdasar karakteristik tertentu
- Prediksi harga saham besok

- Root Mean Squared Error (RMSE)
- Mean Absolute Error (MAE), dll




Klasifikasi:

Memprediksi kelas/kategori dari kasus

- Prediksi kolektibilitas suatu pinjaman
- Prediksi kebangkrutan suatu perusahaan di tahun depan

- Recall, Precision
- F1 Score, dll



Klastering:

Mengelompokkan kasus berdasar kemiripan

- Segmentasi nasabah perbankan
- Pengelompokan pasien yang mirip kasusnya

- Silhouette Score
- Davies-Bouldin Index (DBI), dll



Business Understanding: Produce Project Plan

- Menjelaskan rencana yang akan dilakukan untuk mencapai data science goal dan business goal. Rencana tersebut termasuk langkah-langkah yang dilakukan selama proyek berlangsung termasuk di dalamnya pemilihan teknik dan tools yang akan dipakai.

Output:	<i>Project Plan</i>	Membuat list tahapan pelaksanaan proyek dengan durasinya, sumber daya yang diperlukan, input, output dan dependensi dari tiap tahapan.
----------------	---------------------	--

<i>Initial Assessment of Tools and Techniques</i>	Asesmen awal dari Teknik dan tools yang akan digunakan dalam proyek.
---	--





Hitung Biaya Implementasi AI

Biaya Pengembangan

- Tim pengembang, konsultan/outsource, waktu dari tim internal

Biaya Infrastruktur

- Hardware pendukung proyek (server baru, sewa cloud computing, biaya storage, dll)

Biaya Perangkat Lunak (lisensi software & tools)

Biaya Data (pengumpulan, pembersihan, pengolahan dan pelabelan data)

Biaya Pembangunan (pelatihan) Model AI

Biaya implementasi dan deployment

Biaya pemeliharaan (model AI, infrastruktur, monitoring & troubleshooting)

Biaya pelatihan pengguna

Biaya regulasi dan kepatuhan

Biaya penonaktifan / penggantian

$$ROI = \left(\frac{\text{Total nilai yang dihasilkan} - \text{biaya implementasi AI}}{\text{biaya implementasi AI}} \right) \times 100$$



Analisis Manfaat Non Finansial

Kecepatan pengambilan keputusan

- AI dapat membantu Perusahaan dalam membuat Keputusan lebih cepat

Inovasi

- Implementasi AI mungkin membuka jalan bagi inovasi lebih lanjut

Pengalaman pelanggan yang lebih baik

- Meskipun sulit diukur langsung, pengalaman pelanggan yg lebih baik dapat berkontribusi scr jangka panjang

ayu@informatika.org



Analisis Risiko

Risiko Teknis

- Model AI bisa tidak akurat/tidak tepat
- Model perlu pembaruan dan pemeliharaan agar tetap relevan
- Risiko keamanan sistem dan manipulasi data

Risiko Data

- Data yang salah atau bias menghasilkan Keputusan yang salah
- Potensi pelanggaran privasi dan kebocoran data sensitive
- Kepatuhan regulasi

Risiko Operasional

- Kegagalan infrastruktur dapat mengganggu operasi
- Risiko kegagalan saat integrasi AI dengan sistem lain
- Risiko operasional jika pengguna tidak dilatih dengan baik

Risiko Etika

- AI bisa memperkuat ketidakadilan jika ada bias pada model
- Sulit menjelaskan cara AI membuat Keputusan (black box)
- Siapa yang bertanggung jawab atas keputusan

2. Data Understanding : Mengenali/ mendalami data yang dimiliki

Mengumpulkan Data

Mengumpulkan Data yang Diperlukan



Menelaah data

Menganalisa data secara eksploratif



Memvalidasi Data

Menilai kesesuaian kualitas data dengan masalah yang akan dipecahkan

2. Data Understanding : Mengumpulkan data

Mengumpulkan Data yang Diperlukan

Jumlah Data: Berapa banyak yang dapat diperoleh

Deskripsi Data: Penjelasan arti atribut/ fitur




2. Data Understanding : Menelaah Data


Menganalisa data secara eksploratif (EDA)

Karakteristik Atribut: Deskripsi data (atribut) yang diperoleh

Keterkaitan antar Data: Analisis statistik korelasi, Anova, Chi-Squared,...



22



2. Data Understanding : Memvalidasi Data

Menilai kesesuaian kualitas data dengan masalah yang akan dipecahkan

Laporan Kualitas Data:

- Ukuran Data (Atribut/ fitur dan Jumlah record)
- Deskripsi statistical atribut
- Relasi antar atribut (dan label)
- Visualisasi data



3. Data Preparation

Memperbaiki kualitas data untuk Pemodelan

Memilih dan memilah data

Memilih data yang akan dipergunakan



- Record terpakai
- Atribut terpakai

Membersihkan Data

Meminimalkan noise (tidak lengkap, salah)



- Data lengkap
- Data yang diperbaiki
- Data Pecilan

Mengkonstruksi data

Menambahkan fitur dan transformasi data



- Fitur tambahan (Feature Engineering)
- Transformasi data (standardisasi, transformasi)

Integrasi Data

Menggabungkan data



4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun Skenario Pemodelan

Membuat strategi pencarian model terbaik

A. Memilih Algoritma : Disesuaikan dengan Tugas Analytics yang dipilih

1. k-Nearest Neighbor (k-NN)
2. Naïve Bayes
3. Regression Techniques
4. Support Vector Machines (SVMs)
5. Decision Trees
6. Random Forests
7. Deep Learning Algorithms
8. ...




4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun Skenario Pemodelan

Membuat strategi pencarian model terbaik

B. Membagi data: Sesuai dengan ketersediaan data

1. Data Latih: Untuk mengembangkan model
2. Data Uji: Untuk Mengukur performansi model




4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun Skenario Pemodelan

Membuat strategi pencarian model terbaik

C. Menentukan Langkah Eksperimen:

Untuk mendapatkan model terbaik secara efisien dan efektif



Best Guess

One Factor at A Time



Grid Search

4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun model

Mengembangkan model dengan Teknik ML

Pemilihan Algoritma Machine Learning (ML)
Pembagian Data
Penentuan Langkah Eksperimen



Tidak ada Algoritma yang SELALU TERBAIK untuk setiap dataset! Coba beberapa algoritma!!

4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun model


Mengembangkan model dengan Teknik ML

A. Proses Pelatihan : Untuk mendapatkan model

Data
Latih




Teknik ML



Model

Variable	Type	Definition
BAD	Num	BAD: 1 = applicant defaulted on loan or seriously delinquent; 0 = applicant paid loan
LOAN	Num	LOAN: Amount of the loan request
MORTDTUE	Num	MORTDTUE: Amount due on existing mortgage
VALUE	Num	VALUE: Value of current property
REASON	Char	REASON: DebtCon = debt consolidation, HomeImp = home improvement
JOB	Char	JOB: Occupational categories
YOI	Num	YOI: Years at present job
DEROG	Num	DEROG: Number of major derogatory reports
DELTNO	Num	DELTNO: Number of delinquent credit lines
CLAGE	Num	CLAGE: Age of oldest credit line in months
INQ	Num	INQ: Number of recent credit inquiries
CLNO	Num	CLNO: Number of credit lines
DEBTINC	Num	DEBTINC: Debt-to-income ratio

1. k-Nearest Neighbor (k-NN)
2. Naïve Bayes
3. Regression Techniques
4. Support Vector Machines (SVMs)
5. Decision Trees
6. Random Forests
7. Deep Learning Algorithms




4. Modeling : Mengembangkan Model (Pengetahuan)

Membangun model

Mengembangkan model dengan Teknik ML

B. Proses Pengujian : Untuk mengukur Performansi



Metrik Performansi

TP = True Positives
TN = True Negatives
FP = False Positives
FN = False Negatives

	p' (Predicted)	n' (Predicted)
p (Actual)	True Positive	False Negative
n (Actual)	False Positive	True Negative

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1-score} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

5. Model Evaluation

Mengevaluasi Performansi Model Yang Dihasilkan

Mengevaluasi Model

Mengukur performansi model

Performansi Capaian vs Target
Memilih Model terbaik

Mengevaluasi Proses


Menilai apakah proses sudah maksimal

Review Proses untuk mencari batasan atau kekurangan model






Data Understanding



CRISP-DM – Phase 2: Data Understanding



Collect Initial Data

- **Collect Initial Data** or acquire the data and its access to the data listed in the projects resources. Collecting initial data also means you need to have a checklist of the dataset you have acquired, the dataset location, the methods to acquire the datasets, and record any problems encountered and any solutions to the problems for the other users or project members to be aware of.

Describe Data

- **Describe Data** by examining the properties of the data acquired, provide a description report regarding the format of the data, quantity of data and even the records and fields in each table or datasets.

Explore Data

- **Explore Data** by using data science questions that can be quickly answered through querying, visualization, and reporting or summary report. In this stage, you will be able to find your first or initial hypothesis and their impact on the project.

Verify Data Quality

- **Verify Data Quality** by examining if the data is complete. If the data has errors or are there missing values and if there is, what is the percentage of the missing values versus the overall data obtained.

Collect Initial Data


Menentukan
Kebutuhan Data

Mengambil Data



Menentukan Kebutuhan Data

- Menentukan kebutuhan data adalah proses mengidentifikasi dan mendokumentasikan data yang dibutuhkan untuk melatih model AI yang disesuaikan dengan permasalahan bisnis yang sudah diketahui pada proses sebelumnya.
- Kebutuhan data tergantung pada:
 - Task pemodelan data science yang akan dilakukan (ditentukan pada langkah business understanding)
 - Domain permasalahan dapat menentukan apakah kebutuhannya berupa data terstruktur atau tidak terstruktur
 - Kompleksitas permasalahan atau model yang dibangun



- **Klasifikasi :**

Membutuhkan data berlabel dengan labelnya berupa kelas yang akan diprediksi

- **Regresi :**

Membutuhkan data berlabel dengan labelnya berupa nilai sebenarnya dari data

- **Clustering :** Membutuhkan data tidak berlabel




Data Terstruktur

Terdapat dua jenis informasi mengenai data adalah:

1. Informasi yang menjelaskan struktur data, seperti entitas, atribut, dan relasi.
Informasi ini biasanya dinyatakan dalam bentuk grafik seperti *Entity-Relationship Diagrams* (E-RD).
2. Informasi yang menggambarkan aturan atau batasan yang dapat menjaga integritas data.

Biasanya disebut aturan bisnis (*business rules*), batasan-batasan ini harus dituangkan dalam data dictionary/directory (atau *repository*) suatu organisasi.





Dataset

- A collection of separate (related) sets of information that is treated (manipulated) as a single unit by a computer
(Cambridge / Oxford Dictionary)
- Dataset terdiri atas objek data
 - Kolom merepresentasikan variabel (attributes, features, dimensions).
 - Baris merepresentasikan objek data (samples, examples, instances, data points, tuples). Merepresentasikan entitas.



Contoh Structured Dataset: Automobile Dataset

Automobile Data Set

Download: [Data Folder](#), [Data Set Description](#)

Abstract: From 1985 Ward's Automotive Yearbook



Data Set Characteristics:	Multivariate	Number of Instances:	205
Attribute Characteristics:	Categorical, Integer, Real	Number of Attributes:	26
Associated Tasks:	Regression	Missing Values?	Yes

205 data objects =
205 rows

26 columns

Predict price based on 25 attributes of
automobile data

<http://archive.ics.uci.edu/ml/datasets/Automobile>



Automobile Dataset: Attributes (categorical, integer, real)

Attribute: Attribute Range:

1. symboling: -3, -2, -1, 0, 1, 2, 3.
2. normalized-losses: continuous from 65 to 256.
3. make: alfa-romero, audi, bmw, chevrolet, dodge, honda, isuzu, jaguar, mazda, mercedes-benz, mercury, mitsubishi, nissan, peugot, plymouth, porsche, renault, saab, subaru, toyota, volkswagen, volvo
4. fuel-type: diesel, gas.
5. aspiration: std, turbo.
6. num-of-doors: four, two.
7. body-style: hardtop, wagon, sedan, hatchback, convertible.
8. drive-wheels: 4wd, fwd, rwd.
9. engine-location: front, rear.
10. wheel-base: continuous from 86.6 to 120.9.
11. length: continuous from 141.1 to 208.1.
12. width: continuous from 60.3 to 72.3.
13. height: continuous from 47.8 to 59.8.
14. curb-weight: continuous from 1488 to 4066.
15. engine-type: dohc, dohcv, l, ohc, ohcf, ohcv, rotor.
16. num-of-cylinders: eight, five, four, six, three, twelve, two.
17. engine-size: continuous from 61 to 326.
18. fuel-system: 1bbl, 2bbl, 4bbl, idi, mfi, mpfi, spdi, spfi.
19. bore: continuous from 2.54 to 3.94.
20. stroke: continuous from 2.07 to 4.17.
21. compression-ratio: continuous from 7 to 23.
22. horsepower: continuous from 48 to 288.
23. Peak-rpm: continuous from 4150 to 6600.
24. city-mpg: continuous from 13 to 49.
25. highway-mpg: continuous from 16 to 54.
26. Price: continuous from 5118 to 45400.



Contoh Unstructured Dataset: YouTube Spam

YouTube Spam Collection Data Set

Download: [Data Folder](#), [Data Set Description](#)

Abstract: It is a public set of comments collected for spam research. It has five datasets composed by 1,956 real messages extracted from five videos that were among the 10 most viewed on the collection period.

Data Set Characteristics:	Text	Number of Instances:	1956	Area:	Computer
Attribute Characteristics:	N/A	Number of Attributes:	5	Date Donated	2017-03-26
Associated Tasks:	Classification	Missing Values?	N/A	Number of Web Hits:	63435

<https://archive.ics.uci.edu/ml/datasets/YouTube+Spam+Collection>



YouTube Spam Dataset: Attributes & Data (csv)

COMMENT_ID,AUTHOR,DATE,CONTENT,CLASS

z12pgdhovmrktzm3i23es5d5junfft3f,lekanaVEVO1,2014-07-22T15:27:50,i love this so much. AND also I Generate Free Leads on Auto Pilot & You Can Too! <http://www.MyLeaderGate.com/moretraffic>,1

z13yx345uxepetggz04ci5rjcxehzlrft4,Pyunghee,2014-07-27T01:57:16,<http://www.billboard.com/articles/columns/pop-shop/6174122/fan-army-face-off-round-3> Vote for SONES please....we're against vips....please help us.. & > .& lt; .& lt; ,1

...

z12cdlswetvnejcri04cex0jfwy2u3tzj54,Rafi Hossain,2015-06-05T19:55:08,Honestly speaking except taylor swift and adele i don't like any of the modern day singers. But i must say whenever i hear this song i feel goosebumps. Its quite inspiring!! Thanks miss Perry!,0

z120e5uautvcuper304ccf4bjrjugdpbwrc0k,moaz adnan,2015-06-05T20:01:23,who is going to reach the billion first : katy or taylor ?,0



Pentingnya Menentukan Kebutuhan Data secara Tepat



<https://www.ibm.com/blogs/business-analytics/data-driven-analytics-vision/>

- Kualitas, kuantitas, dan keberagaman data penting dalam pembelajaran mesin.
 - Data berkualitas rendah akan menyebabkan hasil/model berkualitas rendah
- > Business goal yang tidak tercapai

Menentukan Kebutuhan Data Dilakukan Secara iteratif



- Apa yang diperlukan model pembelajaran mesin?
- Bagaimana hasil pemodelan menggunakan data tsb?
- Apakah diperlukan penambahan atau pengumpulan data lagi?

Sumber Data

Download dataset yang ada (open, publik)

- Website kumpulan dataset
- Link pada makalah

Manual labeling

- Anotasi manual oleh annotator manusia

Data observasi

- Log aktifitas
- Rekap data periodik

image	label
	cat
	not cat
	cat
	not cat

user ID	time	price (\$)	purchased
4783	Jan 21 08:15.20	7.95	yes
3893	March 3 11:30.15	10.00	yes
8384	June 11 14:15.05	9.50	no
0931	Aug 2 20:30.55	12.90	yes

Metode Pengumpulan Data


1. Pengambilan data secara manual
2. Pengambilan data melalui API, contoh melalui API Kaggle atau Twitter
3. Pengambilan data melalui web scraping
4. Pengambilan data melalui akses langsung ke basis data relasional yang ada.




Label Data

Label/target/variable dependent : attribute/kolom/field yang menjadi sasaran/target untuk diprediksi.

- Disebut variable dependent, karena nilai dari attribute ini tergantung dari nilai atribut-atribut yang lain.
- Label/target biasanya disimbolkan dengan huruf y .
- y merupakan fungsi dari atribut independent (biasanya disebut x).
 - Jadi fungsi target:
 - persamaan y merupakan fungsi dari x : $y = f(x)$.



Contoh Data Berlabel



Computer Vision:

- Label pada gambar, piksel, atau *key point*, batas gambar digital.
 - Misal: produk vs. gaya hidup; objek wajah vs non wajah, objek hewan vs non hewan



Pemrosesan Bahasa Alami

- sentimen atau makna uraian teks
- Identifikasi bagian ucapan
- klasifikasikan kata benda
- Identifikasi teks, gambar, PDF, atau file lainnya.



Pemrosesan Audio

- Rangkaian teks dari audio.



Cara Pelabelan Data

Dua cara pelabelan data:

1. Pelabelan Manual


- Dilakukan oleh manusia
 - Pakar domain bisnis yang menjadi tujuan pemodelan
 - misal dokter radiologi melabeli foto thorax adanya infeksi paru-paru
 - Orang awal/biasa
- *Strong labelled*

2. Pelabelan Otomatis:

- **Pelabelan sintetis** (*weakly labelled*) :
 - Data sintetis dihasilkan oleh model generatif yang dilatih dan divalidasi pada dataset asli (pelabelan oleh mesin)
 - Dilakukan jika pelabelan manual mahal
 - Diperlukan teknik pemodelan data yang sesuai untuk data weakly labelled (model yang robust)
- **Pemrograman data** :
 - Penulisan fungsi pelabelan — skrip yang secara terprogram melabeli data.
 - Contoh: Data transaksi fraud atau tidak yang sudah dilabeli oleh kode program



Pemahaman Data (Describe, explore, verify data quality)





Tujuan Pemahaman Data

- Memahami isi data
- Menguji kualitas data
- Memastikan jumlah data
- Menemukan insight awal



Proses Pemahaman Data

1. Mendeskripsikan data
2. Melakukan analisis untuk memastikan kualitas data
3. Melakukan eksplorasi data



1. Mendeskripsikan Data

Data Understanding

Proses Pemahaman Data:

Mendesripsikan Data

- Karakteristik Utama yang dideskripsikan:
 - a. **Sumber data**
 - Basis data lembaga
 - Artikel berita, dll
 - b. **Ukuran**
 - Jumlah instan
 - Jumlah atribut dan apa saja atributnya
 - c. **Mengidentifikasi Tipe Data dari Atribut Data**
 - Tipe atribut
 - Nilai atribut: *value range* (untuk numerik) atau value set (untuk nominal)
 - d. **Statistik Deskriptif: Perhitungan statistik dasar (mean, variance, dll)**

Mengidentifikasi Tipe Data dari setiap Atribut/Fitur

Tujuan mengidentifikasi tipe data dari fitur:

- Menjelaskan karakteristik sebuah fitur
- Menetapkan analisis statistik yang tepat untuk fitur tersebut.

Tipe Data sebuah fitur (Stanley Smith Stevens, 1940):

- Nominal
- Ordinal
- Interval
- Rasio



Tipe Data Fitur (Skala Pengukuran)

Kategori	Type Data	Karakteristik	Contoh Fitur
Kualitatif	Nominal	Tidak ada urutan dari kategori.	- Jenis kelamin - Golongan darah - Agama/ Kepercayaan
	Ordinal	Kategori memiliki urutan tetapi jarak antar data tidak bermakna.	- Nilai (A-E) - Status Sosial-Ekonomi - Tingkat pendidikan - Tingkat persetujuan - Skala Likert.
Kuantitatif	Interval	Memiliki urutan, jarak antara dua nilai bermakna. Nilai nol tidak menyatakan ketiadaan, tapi hanya berupa salah satu nilai dari rentang nilai yang ada	- Tahun - Skor test IQ - Likert scale
	Ratio	Memiliki semua karakteristik data interval dengan nilai “nol” berarti “tidak ada”.	- Tinggi objek - Panjang benda - Berat objek

Contoh Data Task Klasifikasi

Contoh kasus:


Memprediksi spesies bunga iris (kolom label: species)

apakah:

- Iris-setosa,
- Iris-versicolor, atau
- Iris-virginica


berdasarkan:

- Panjang sepal (SepalLengthCm)
- Lebar sepal (SepalWidthCm)
- Panjang daun bunga (PetalLengthCm)
- Lebar daun bunga (PetalWidthCm)




Pada task **klasifikasi**, label merupakan variabel **kategorikal**


Iris setosa



Iris versicolor



Iris virginica



SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5	3.6	1.4	0.2	Iris-setosa
5.4	3.9	1.7	0.4	Iris-setosa
4.6	3.4	1.4	0.3	Iris-setosa
5	3.4	1.5	0.2	Iris-setosa
4.4	2.9	1.4	0.2	Iris-setosa

x = variabel independen

y = variabel dependen / target / label

Contoh Data Task Regresi

Contoh kasus:

Memprediksi harga rumah (kolom label: price)

berdasarkan:

- luas (area)
- jumlah kamar tidur (bedrooms)
- jumlah kamar mandi (bathrooms)
- berapa kali rumah itu ditinggali sebelumnya (stories)
- apakah terletak di jalan raya atau tidak (mainroad)
- apakah memiliki ruang tamu atau tidak (guestroom)

Pada task **regresi**, label merupakan variabel **kontinu**

- apakah memiliki basement atau tidak (basement)
- apakah memiliki pemanas air atau tidak (hotwaterheating)
- apakah memiliki AC atau tidak (airconditioning)
- apakah memiliki tempat parkir atau tidak (parking)
- apakah berada di daerah yang favorit atau tidak (prefarea)
- apakah memiliki perabot lengkap / ada beberapa perabot / tidak ada perabot (furnishingstatus)

area	bedrooms	bathrooms	stories	mainroad	guestroom	basement	hotwaterheating	airconditioning	parking	prefarea	furnishingstatus	price
7420	4	2	3	yes	no	no	no	yes	2	yes	furnished	13300000
8960	4	4	4	yes	no	no	no	yes	3	no	furnished	12250000
9960	3	2	2	yes	no	yes	no	no	2	yes	semi-furnished	12250000
7500	4	2	2	yes	no	yes	no	yes	3	yes	furnished	12215000
7420	4	1	2	yes	yes	yes	no	yes	2	no	furnished	11410000
7500	3	3	1	yes	no	yes	no	yes	2	yes	semi-furnished	10850000
8580	4	3	4	yes	no	no	no	yes	2	yes	semi-furnished	10150000
16200	5	3	2	yes	no	no	no	no	0	no	unfurnished	10150000
8100	4	1	2	yes	yes	yes	no	yes	2	yes	furnished	9870000

x = variabel independen

y = variabel dependen / target / label

Contoh Data Task Clustering

Contoh kasus:

Mengelompokkan pelanggan ke dalam beberapa kelompok

Pada clustering, data tidak berlabel

berdasarkan:

- jenis kelamin (Gender)
- umur (Age)
- pendapatan tahunan (Annual Income (\$))
- skor pengeluaran (Spending Score (1-100))
- pekerjaan (Profession)
- lama bekerja (Work Experience)
- Banyak anggota keluarga (Family Size)

Gender	Age	Annual Income (\$)	Spending Score (1-100)	Profession	Work Experience	Family Size
Male	19	15000	39	Healthcare	1	4
Male	21	35000	81	Engineer	3	3
Female	20	86000	6	Engineer	1	1
Female	23	59000	77	Lawyer	0	2
Female	31	38000	40	Entertainment	2	6
Female	22	58000	76	Artist	0	2
Female	35	31000	6	Healthcare	1	3
Female	23	84000	94	Healthcare	1	3
Male	64	97000	3	Engineer	0	3

x = variabel independen

Statistik Deskriptif

- **Rangkuman informasi atau karakteristik dari sejumlah data.**
- **Ukuran Pemusatan:** ukuran yang menjelaskan titik pusat data
 - Mean ($\bar{x}$) = $\sum_{i=1}^n (x_i/n)$
 - Kuartil ke-1 (Q_1) adalah nilai data dimana 25 % dari data setelah disortir menaik bernilai lebih kecil dari nilai tersebut.
 - Kuartil ke-2 atau Median (Q_2) adalah nilai data dimana separuh dari data setelah disortir menaik bernilai lebih kecil dari nilai tersebut.
 - Kuartil ke-3 (Q_3) adalah nilai data dimana 75 % dari data setelah disortir menaik bernilai lebih kecil dari nilai tersebut.
 - Mode (Modus) adalah nilai yang paling sering muncul pada sekumpulan data
- **Ukuran Variabilitas:** ukuran variabilitas data
 - Varians atau variance (s^2) = $\sum_{i=1}^n (x_i - \bar{x})^2 / (n - 1)$
 - Standar deviasi (s) = $\sqrt{s^2}$
 - Kisaran atau range = $x_{max} - x_{min}$

- Alat yang sangat penting dalam dunia pengumpulan, penyajian, dan interpretasi data
- Digunakan untuk mengenali pola, tren, dan informasi yang terkandung dalam data.

Statistik Deskriptif

Jenis data	Ukuran Pemusatan	Ukuran Variabilitas	Sebaran Data
Nominal	Modus	--	Frekuensi nilai, Proporsi
Ordinal	Median, Modus	--	Frekuensi nilai, Proporsi
Interval	Mean, Median, Mode	Variance, Kuartil, Persentil, Range	Frekuensi interval nilai
Ratio	Mean, Median, Mode	Variance, Kuartil, Persentil, Range	Frekuensi interval nilai

Contoh Mendeskripsikan Data

Automobile Data Set

Download: [Data Folder](#), [Data Set Description](#)

Abstract: From 1985 Ward's Automotive Yearbook



205 data
objects = 205
rows

Data Set Characteristics:	Multivariate	Number of Instances:	205
Attribute Characteristics:	Categorical, Integer, Real	Number of Attributes:	26
Associated Tasks:	Regression	Missing Values?	Yes

26 columns

Predict price based on 25
attributes of automobile data

<http://archive.ics.uci.edu/ml/datasets/Automobile>

Contoh Mendeskripsikan Data

Automobile Dataset: Attributes (categorical, integer, real)

Attribute: Attribute Range:

1. symboling: -3, -2, -1, 0, 1, 2, 3.
2. normalized-losses: continuous from 65 to 256.
3. make: alfa-romero, audi, bmw, chevrolet, dodge, honda, isuzu, jaguar, mazda, mercedes-benz, mercury, mitsubishi, nissan, peugot, plymouth, porsche, renault, saab, subaru, toyota, volkswagen, volvo
4. fuel-type: diesel, gas.
5. aspiration: std, turbo.
6. num-of-doors: four, two.
7. body-style: hardtop, wagon, sedan, hatchback, convertible.
8. drive-wheels: 4wd, fwd, rwd.
9. engine-location: front, rear.
10. wheel-base: continuous from 86.6 to 120.9.
11. length: continuous from 141.1 to 208.1.
12. width: continuous from 60.3 to 72.3.
13. height: continuous from 47.8 to 59.8.
14. curb-weight: continuous from 1488 to 4066.
15. engine-type: dohc, dohcv, l, ohc, ohcf, ohcv, rotor.
16. num-of-cylinders: eight, five, four, six, three, twelve, two.
17. engine-size: continuous from 61 to 326.
18. fuel-system: 1bbl, 2bbl, 4bbl, idi, mfi, mpfi, spdi, spfi.
19. bore: continuous from 2.54 to 3.94.
20. stroke: continuous from 2.07 to 4.17.
21. compression-ratio: continuous from 7 to 23.
22. horsepower: continuous from 48 to 288.
23. Peak-rpm: continuous from 4150 to 6600.
24. city-mpg: continuous from 13 to 49.
25. highway-mpg: continuous from 16 to 54.
26. Price: continuous from 5118 to 45400.

<http://archive.ics.uci.edu/ml/datasets/Automobile>

2. Menganalisis dan Mengeksplorasi Data

Data Understanding

Analisis Data

Analisis yang dilakukan untuk memeriksa data dan menentukan bagaimana data harus diproses sebelum digunakan untuk pemodelan


Tujuan analisis data:

Memeriksa kesiapan data untuk digunakan pada pemodelan, baik dari sisi kelengkapannya maupun kualitasnya



Pemeriksaan Kelengkapan Data

- Apakah semua data yang diperlukan sudah ada?
- Apakah semua variabel/kolom yang diperlukan sudah ada?
- Apakah data yang ada sudah mencakup periode waktu yang diperlukan?
- Apakah jumlah instans sudah mencukupi
- Apakah sudah mencakup sebanyak mungkin kasus dunia nyata?
- Apakah jumlah data untuk setiap kelompok label sudah berimbang?



Pemeriksaan Kualitas Data

- Apakah ada inkonsistensi data?
 - Apakah ada klasifikasi atau pengkodean yang tidak dapat dijelaskan?
 - Apakah ada masalah dalam format seperti tanggal yang tidak biasa, karakter ASCII?
- Apakah ada item yang tidak lengkap atau hilang (*missing values*)?
- Apakah ada duplikat data?
- Apakah ada nilai yang tidak biasa atau pencilan yang jelas?
- Seperti apa hubungan antar atribut data dan hubungan antara setiap atribut dengan labelnya? (ada korelasi atau tidak)

Noisy Data and Inconsistent Data

- Tipe data kotor:
 - Class (label) noise
 - Sampel yang kontradiksi
 - Sampel yang salah label
 - Attribute noise
 - Kesalahan entri data
 - Pelanggaran terhadap konstrain
 - Pengulangan white space (karakter yang tidak terbaca atau tidak terlihat)
 - Perbedaan unit pengukuran (contoh: centimeter dengan meter)
 - Perbedaan level agregasi (contoh: akumulasi per hari dengan per minggu)

Attr1	Attr2	Class
0.25	red	positive
0.25	red	negative
1.02	green	positive
0.99	green	negative

contradictory

error at data entry

mislabeled

<https://sci2s.ugr.es/noisydata>

Temukan Data yang Salah!

ID	A1	A2	A3	A4	C
1	1	2	1	1	y1
2	2	1	1	1	y2
3	3	5	2	4	y1
4	2	2	2	2	y2
5	3	5	2	4	y2
6	6	7	5	8	y1
7	9	4	3	1	y1

<https://pdfs.semanticscholar.org/ee88/ae92d19e208f15d3613016266bb13da8fc98.pdf>

Temukan Data yang Salah!

	A	B	C	D	E	F	G
1	First name	Last name	January	February	March	Q1 Sales	Region
2	Darrel	Alston	\$ 11,896	\$ 2,552	\$ 11,350	\$ 25,798	East
3	David	Terrell	\$ 9,763	\$ 1,749	\$ 8,678	\$ 20,190	South
4	Gwendolyn	Cameron	\$ 9,421	\$ 5,585	\$ 10,423	\$ 25,429	East
5	Katell	Hall	\$ 3,291	\$ 2,610	\$ 13,692	\$ 19,593	Norht
6	Honorato	Howard	\$ 11,746	\$ 6,756	\$ 10,471	\$ 28,973	West
7	Nehru	Rose	\$ 8,603	\$ 5,907	\$ 1,682	\$ 16,192	West
8	Upton	Shields	\$ 10,955	\$ 4,914	\$ 11,539	\$ 27,408	West
9	Germane	Holman	\$ 11,561	\$ 8,547	\$ 8,433	\$ 28,541	North
10	Elliott	Hall	\$ 9,318	\$ 5,857	\$ 4,935	\$ 20,110	North
11	Illana	Erickson	\$ 3,709	\$ 13,401	\$ 3,431	\$ 20,541	Wst
12	Lani	Spears	\$ 5,620	\$ 14,252	\$ 8,894	\$ 28,766	East
13	Clementine	Pope	\$ 8,901	\$ 10,143	\$ 13,573	\$ 32,617	South

<https://edu.gcfglobal.org/en/excel-tips/a-trick-for-finding-inconsistent-data/1/>

Missing values Data

Missing values

PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	male	22	1	0	A/5 21171	7.25		S
2	1	1	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	female	26	0	0	STON/O2. 3101282	7.925		S
4	1	1	female	35	1	0	113803	53.1	C123	S
5	0	3	male	35	0	0	373450	8.05		S
6	0	3	male		0	0	330877	8.4583		Q

<https://freecontent.manning.com/pre-processing-data-for-modeling/>

Data yang Tidak Konsisten


Data yang tidak konsisten: mengandung perbedaan dalam nama atau kode, atau perbedaan antara instan yang sama yang biasanya terjadi ketika data dikumpulkan dari berbagai sumber

Age	BirthDate	...
18	30 June 2000	...
19	30 June 2000	...
...	...	...

ID	GPA	...
01	3.25	...
01	3.67	...
...	...	...

ID	Rating	...
1	A	...
2	B	...
3	1	...
4	3.5	...

Identifikasi Pencilan



19 Data:

5, 7, 10, 15, 19, 21, 21,
22, 22, 23, 23, 23, 23, 23,
24, 24, 24, 24, 25

<https://www.khanacademy.org/math/statistics-probability/summarizing-quantitative-data/box-whisker-plots/a/identifying-outliers-iqr-rule>

Aturan Umum:

Low outlier $< Q1 - 1.5 * IQR$

High outlier $> Q3 + 1.5 * IQR$

$IQR = Q3 - Q1$


$Q1: 19 ; Q3: 24$

$IQR = Q3 - Q1 = 24 - 19 = 5$

Low outlier $< 19 - (1,5 * 5)$

High outlier $> 24 + (1,5 * 5)$

Identifikasi Pencilan menggunakan Visualisasi: Whisker Plot




Median: 23; Q1: 19 ; Q3: 24


$IQR = Q3 - Q1 = 24 - 19 = 5$

$Min = 19 - 7.5 = 11.5$


$Max = 24 + 7.5 = 31.5$



Whisker Plot *tanpa* Pencilan



Whisker Plot *dengan* Pencilan




Identifikasi Pencilan Menggunakan STD Fitur

- STD (*standard deviation*) = $\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$,
dimana: x_i adalah nilai fitur ke- i dan n adalah banyaknya sampel data
- Sebuah data x dikategorikan sebagai *outlier* apabila: $x < (\bar{x} - 3 STD)$ atau $x > (\bar{x} + 3 STD)$

Calculating Standard Deviation

$$S_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

- n = The number of data points
 x_i = Each of the values of the data
 $\bar{x}$ = The mean of x_i



ThoughtCo.



Data yang Tidak Berimbang

Class	Frequency
A	1000
B	10

Majority
class

Minority
class




Eksplorasi Data Menggunakan Grafik

Diagram Univariat

Contoh Pie Chart:


Pengguna Mode Transportasi di DKI Jakarta



Tipe data: Nominal, Ordinal

Contoh Bar Chart:


Sebaran Pemilik Hewan di Kota Bogor



Tipe data: Nominal, Ordinal

Contoh Histogram:

Sebaran Nilai Matematika Siswa




Tipe data: Interval, Rasio

Eksplorasi Data Menggunakan Grafik


Diagram Bi/Multivariat

Contoh Box Plot 1 Fitur:



Tipe data: Interval, Rasio

Contoh Box Plot 3 Fitur:




Eksplorasi Data Menggunakan Grafik

Diagram Bi/Multivariat

Contoh Scatter Plot:


Sebaran Tinggi Badan dan Berat Badan dari Sampel Mahasiswa Univ. XYZ, 1 Agustus 2022



Tipe data: Interval, Rasio

Contoh Heatmap

Sebaran Suhu Udara di Kota X 1949-1960



Tipe data: Interval, Rasio

3. Membuat Laporan Telaah Data

Data Understanding

Laporan Telaah Data

- Dibuat setelah selesai mendeskripsikan, menganalisis, dan mengeksplorasi data
- Laporan berisi:
 - Deskripsi data
 - Deskripsi kualitas data
 - Deskripsi kuantitas data
- Laporan telaah data akan digunakan pada tahap berikutnya, yaitu persiapan data untuk pemodelan untuk menentukan langkah apa saja yang perlu dilakukan di tahap persiapan data.



Thank You

